

Chapter-2

20 / 09 / 2024

- Model-1) Dataset
- Model-2) Train / Validation / Test
- Model-3) Feature Scaling
- Model-4) Regression
- Model-5) Nonlinear Regression
- Model-6) Underfitting / Overfitting
- Model-7) Evaluation
- FINAL PROJECT

Temperature	voltage	current	sample 1 $\rightarrow$ [90, 24, 10]
70	24	10	sample 2 $\rightarrow$ [75, 24, 12]
75	24	12	feature


sample $\Rightarrow$ modelin her setinde girdiye = her bir veri örneğidir
 feature $\Rightarrow$ her sampledeki özellikler / boyutlar

$$X = \begin{bmatrix} 1 & 2 & 9 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \quad Y = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}$$

sample 1 $\rightarrow$ [1, 2, 9] $\rightarrow$ 0
 sample 2 $\rightarrow$ [4, 5, 6] $\rightarrow$ 1
 sample 3 $\rightarrow$ [7, 8, 9] $\rightarrow$ 1

X.shape = (3, 3)

Sample Sayısı
 Feature Sayısı



Diferans $\rightarrow$ Farklı, Random Flow

rng $\rightarrow$ Random Number Generator

21 / 09 / 2024

rng = np.random.default_rng(42)
 generator nesnesi oluşturur $\rightarrow$ seed başlangıç durumu belirler

rng1.permutation(10)
 rng2.permutation(10) $\rightarrow$ Aynı sonucu üretir

Herden rng kullanılıyor

* proje içinde farklı yerlerde randomness var

- weight initialization
- Dataset split
- Batch shuffling
- Augmentation

np.random

kullanılıyor $\rightarrow$ Bizim bir random aldığımız var

A = random = 7 $\rightarrow$ X = random = 7, 7 değeri
 B = random = 5 $\rightarrow$ A = random = 5, yeni değer
 C = random = 2 $\rightarrow$ B = random = 2, oldu
 (1) C = random = 1, atış baskıldı

A, B, ve C min

* Sonuçlar, değeri ki bizim nekeci hepsi global random kullanıyor

* rng ile kendi aldığımız kurarı böylece yapılan değeriyle bir birini etkilemez

data_rng

7 $\rightarrow$ 3 $\rightarrow$ 2

weight_rng

5 $\rightarrow$ 4 $\rightarrow$ 6

21/08/2024

rng1 = np.random.default_rng(42)
rng2 = np.random.default_rng(42)

rng1, permutation (5) } Aym
rng2, permutation (5) } karistive
[A, B, C, D, E]

B, D, E, C, A ise
5 degeri ikin permutation iki ng ikin de ayar birisr

çğer rng1, permutation (42) yapilirs-

• ikisi de rng2 için
• Farklı random
• Aleasna Sathiptir

ÖZETLE

Normal random:

weight $\Rightarrow$ A, B, C
split $\Rightarrow$ D
shuffle $\Rightarrow$ E, F

RNG kullanisak:

weight-rng
A, B, C, D, E
data-rng
A, B, C, D, E
shuffle-rng
A, B, C, D, E

* Hepsinin beedi aksr var birbirini etkilemeyecek

evaluate -> fontisyonu ile traindeki

egitim sonucundaki tahmin ile gercek
degerin loss faultu kulllanilmasina gerek

21/09/2024

evaluate -> sadece tahmin yap laka puru hesapla

* val, los ile loss salanac, icin

Fit() icine history = { "loss" : loss,
icinde sadece ve
return ise history
donder

* history -> val-loss
loss

Fit() icinde arkte egitimin gerusini de kayit altına alinir

3) Scaling [özellikler]

* Feature Scaling

ÖRNEK

$x_1 = 5$
 $x_2 = 500$
 $y = 0.01$

$\frac{\partial L}{\partial x_1} = 0.1$
 $\frac{\partial L}{\partial x_2} = 0.1$
 $\frac{\partial L}{\partial y} = 0.1$
 $\frac{\partial L}{\partial x_1} \cdot \frac{\partial L}{\partial y} = 0.1 \cdot 0.1 = 0.01$
 $\frac{\partial L}{\partial x_2} \cdot \frac{\partial L}{\partial y} = 0.1 \cdot 0.1 = 0.01$

$w_1 = 1$
 $w_2 = 1$
olsun
başlangıca

$w_1^{new} = w_1 - \eta * w_1 - gradient \rightarrow 1 - 0.01 * 0.5 = 0.995$
 $w_2^{new} = w_2 - \eta * w_2 - gradient \rightarrow 1 - 0.01 * 500 = 0.500$

değisim $w_1 = 0.005$ $w_2 = 0.500$

100x

$w_1 \rightarrow 0.005$
 $w_2 \rightarrow 0.500$
 negatif } model eğitilince bir yonde hassas bir yonde
 agresif hale gelir

22.09.2026

Gec veriyi ölçeklendirilerek (scaling)

$X_1: 0 \rightarrow 10$
 $X_2: 0 \rightarrow 1000$

Min-max scaling

$$X' = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

$$X'_1 = \frac{5-0}{10-0} \Rightarrow 0.5$$

$$X'_2 = \frac{500-0}{1000-0} = 0.5$$

$$\begin{matrix} X'_1 = 5 \\ X'_2 = 500 \\ w_1 = 1 \\ w_2 = 1 \end{matrix}$$

gradiyent değeri

iteisi içinde $\times$ scaling inputların boyutları aynı olur farklı ağırlıklarla

gradiyentlerin de aynı farklı ölçeklerde olmasının etkisi

- Optimizasyon aşamasında bu problem var:

$$X_1 = 5$$

$X_2 = 500$ } 100x daha büyük

bu nedenle ikinde değeri hale getirilerek aynı scaling kullanılır

$w_1 \rightarrow$ küçük adim
 $w_2 \rightarrow$ büyük adim

Scaling yapılıp değeri hale getirilerek ikinde

Loss } Model seçili sonra
 31 } Sadece gittiyi için
 330 } Loss bir değeri bir
 0.83 } gitseniz
 85 }

Standardization

ortalama & standart sapma

$$X' = \frac{X - \mu}{\sigma}$$

* her feature kendi içinde değeriyle ilgiliye bakılır

22.09.2026

$X_1 \rightarrow 20 - 60$
 $X_2 \rightarrow 20,000 - 50,000$

$20 = -2$
 $30 = -1$
 $50 = +1$
 $60 = +2$

Ölçüde artış miktarına bakılır şimdi her birini kendi içinde değeriyle ilgiliye

gradiyentlerin değeri data değeri hale getirilir

AMG:

Feature ölçekleri $\rightarrow$ gradiyent ölçekleri $\rightarrow$ loss değeri

Feature ölçekleri $\rightarrow$ gradiyent değeri $\rightarrow$ data değeri $\rightarrow$ loss değeri

Scaling sonrası

Min-max Normalization

Standardization / Z-score

data verimli gradiyent

Min-max scaling / Normalization

$X = [10, 20, 30, 40, 50]$ ancak 0 ile 1 arasında farklılık

$10 \rightarrow 0$ olarak $50 \rightarrow 1$ olarak

Yeni dataset $\rightarrow X = [0, 10, 20, 30, 40]$

Abdül 2) max değeri 1 olsun yavın $X_{\max} - X_{\min}$ yap

$\frac{0}{40}, \frac{10}{40}, \frac{20}{40}, \frac{30}{40}, \frac{40}{40}$

$$\frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

Veri Data leakage (veri sızıntısı) → bir modelin eğitim sürecinde normalde bulunmayan verileri (test / doğrulama verisi gibi) yanlışlıkla öğrenmektedir.

22/09/2024

ÖB Aynı videoyu hem train hem validde kullanmak

- Yalancı yüksek başarı (accuracy %99 gibi)
- kötü genelleme
- Yalancı başarılar

Test verisini Normalite etme traindeki normalite değeri kullanılır

$$\text{train} = [10, 20, 30, 40, 50] \\ (0, 9, 85, 50, 0, 35, 1)$$

Modelin bilgi

$$\text{Ger test set} = [15, 35, 45] \text{ ise } 35 \text{ için } \frac{35-15}{45-15} = 0,667$$

YAPAY

Bata sein train sette bulun kullanılır

$$\frac{35-10}{50-10} = \frac{0,625}{0,8} \text{ yani traindeki bilgilerin bütün}$$

Modelin traindeki bilgileri

Gerçek Hayat Kısıtlılığı Scaling yapmadan önce

Train	Val	Test	x = [25, 3000, 3] olsun
10	25	35	3000 hepsini domine
20	30	45	edecği için diğerlerinde
30	35	60	yeterecek kadar data yok
40	40	70	etki edecektir
50	45	100	

Auto Scaling Sources

50 → 1
40 → 0,75
30 → 0,50
20 → 0,25
10 → 0

olur 1-0 arasında 22/09/2024

Normalite edilir

Testin a yüksek 100 skoru bile

B) Standardization (Z-score scaling)

$$x = [10, 20, 30, 40, 50] \text{ Ortalama } \mu = \frac{10+20+30+40+50}{5} = 30$$

10 → ort-20
20 → ort-10
30 → ortalaam
40 → ort+10
50 → ort+20

Standard sapma = varyasyon ortalamadan ne kadar uzakta olduğunu söyler → uzaklığa böl

$$\frac{x - \mu}{\sigma} = z\text{-score}$$

bu değer ortalamadan ne kadar standart + sapma, örneğinde

varian ort göre kavramı std sapma ile ölçülür

ÖRNEĞİN σ (standard sapma):

$$\sigma = \sqrt{\frac{(10-30)^2 + (20-30)^2 + (30-30)^2 + (40-30)^2 + (50-30)^2}{5}} = \sqrt{\frac{200}{5}}$$

$$\sigma \approx 14,14$$

x=10 için:

$$\frac{10-30}{14,14} \approx -2,414$$

4) → inverse - transform (self, X-scaled)

23/09/2024

RPM tahmin ediyorduk [1000-5000 arası]
hedef (y) değeri [0-1] oversize scale etti
model tahmin yaptı çıktı → 0.95
gerçek RPM değeri nasıl çeviririz

$$(X - X_{\min}) = \alpha \rightarrow \alpha = (X_{\max} - X_{\min}) + X_{\min} \approx X$$

$$\frac{X - Y}{\sigma} = \alpha \rightarrow \left[(\alpha \cdot \sigma) + \mu \right] = X$$

Fit-tranform() sadece train verisine yapılır

4) Linear Regression

Tez boyutta: $y = wx + b$ 2 boyutlu uzayda 1 doğru

40e boyutta: $y = w_1x_1 + w_2x_2 + w_3x_3 + b$ 3 boyutlu uzayda
4 boyutta → hiper düzlem bir düzlem

Linear Regression → Aktivasyon fonksiyonu linear olan tek bir nörondur.

1 bir nöronu yine sigmoid/relu/softmax kullanırsan sadece linear bir çıktı alırsın

Linear regression → 3x2 gibi bir fonksiyonu modelleyebilir
çünkü linear aktivasyon fonksiyonu birleştirebiliriz
kendi çıktısıdır

Linear

Saat 1 → 300 Ücret

2 → 600

3 → 900

4 → 1200

Sayısal tahmin yapmak için kullanılan
basit bir makine öğrenmesi modelidir.

1 Nöron = Linear Regression + Aktivasyon Fonksiyonu
 $X_1 \cdot w_1 + X_2 \cdot w_2 + b \rightarrow \text{ReLU}$


3 olan veri → 10 dır işleme ama ortaya 0.07'lik
gürültü eklersek istediğimize sonrak 10.07 gibi bir değer çıkar

[noise = 0.01]

gerçek $w_1 \rightarrow 3.00$ $w_2 \rightarrow 2.00$ $w_3 \rightarrow 5.00$ ± 0.01 gürültü
öğretilen $w_1 \rightarrow 2.99$ $w_2 \rightarrow 2.01$ $w_3 \rightarrow 4.99$ ± 0.01 gürültü

5) Nonlinear Regression

gerçek boyut 20 sıklıkla 20 → 60 ortalamada RPM artar
60 → 100 kadar RPM düşer



Tez nöron içinde $y = wx + b$ gibi
linear bir denklemleri aktivasyon
fonksiyonu kullanarak non-linear
hale getirilir.

1 Nöron = Aktivasyon fonksiyonu

1 nöron → 1 kırılımlı nöron yapar.

4 nöron → 4 farklı nöron yapar

Aralarında non-linear aktivasyon fonksiyonları
yeterli sayıda nörona sahip bir jeli katman,
her eğriyi dilediğini hassasiyetle öler

Linear Reg: veriler

arasındaki dağılım 24/09/2024

ilişkisini öğrenip

Sayısal tahmin yapmak için kullanılan

basit bir makine öğrenmesi modelidir.


25/03/2024

- Model aynı bilgiyi sergilerken çok göstermek
- * Aynı verinin gösterdiği gibi model artık oradan her türlü etesine göre çalışır

Yeni model sadece 4 tane veri ile kurulmuş olur
 Şekil ve test veri değiştirilmeden etesine göre çalışır


Underfitting olmasının nedenleri: $\rightarrow$ yetersiz kapasite

- Elde edilen verilerle fiyat tahmini yapan model sadece fiyat olarak tahmin yapamaz
- Yetersiz eğitim: model öğrenme aşamasında eğitimi durdurulmuş
- Öğrenme hızını azaltı dersi olursa



Overfitting aşamaları gösteren olarak $\rightarrow$ L2 regularization

1) L2 regularization: Modelin aşırı karmaşıklığına karşı önlem



Overfitting: Bir şeyin en optimum noktasıdır

25/03/2024

$\frac{d^2}{dx^2} = w$ Eğer eğrilik w ise $(w=0.1)$
 girildiği ne kadar eğrilik ne kadar eğrilik

Eğer eğrilik w ise $(w=100)$
 girildiği ne kadar eğrilik ne kadar eğrilik

Yeni modelin veriyi etesine göre eğilim
 Eğrilik w ise $(w=0.1)$ eğrilik ne kadar eğrilik
 Eğrilik w ise $(w=100)$ eğrilik ne kadar eğrilik

L2 regularization
 $\frac{1}{N} \sum (\hat{y} - y)^2$ Loss fonksiyonu farkı sifir yapar
 eğrilik ne kadar eğrilik

Toplam kayıp = Tahmin hatası + L2 ceta puanı

$$\frac{1}{N} \sum (\hat{y} - y)^2 + \frac{\lambda}{2N} \sum w^2$$

λ = Overfitting olur
 Eğrilik ceta puanına katkısını gösterir

λ = Model eğrilik ne kadar eğrilik ne kadar eğrilik

Backprop.

$$\frac{\partial \text{Total Loss}}{\partial w} = \frac{\partial \text{MSE}}{\partial w} + \frac{\lambda}{N} w$$

$$w_{\text{yeni}} = w_{\text{eski}} - \eta \left(\frac{\partial \text{MSE}}{\partial w} + \frac{\lambda}{N} w_{\text{eski}} \right)$$

$\Rightarrow 0.9995$

3) Dropout



overfitting'i önlemek için:
 → Nöronların belirli kısmını geçici olarak kapatarak (oldukça) 26/09/2026 eğitimi devam etme yöntemidir

1. Seçimsel rastgele

Normal bir sinir ağından birkaç nöron bastırma/kale yapılabilir ve diğer nöronların ağırlarını hesaplamaları kapatılacağı anlamına gelir (co-adaptation)

Rastgele nöronları kapatma


- Hiçbir nöron bir diğerine güvenmez
- Her nöron kendi başına faydalı bir feature öğrenmek zorunda kalır
- Model tek yönlü bağlı kalma alternatifler geliştirir



→ Model yeni yollar keşfetmek zorunda kalır
 → parçaları olur
 değişim sağlama daha dengeli

2. Sub-network

Bir katmanda N tane nöron varsa, her adında farklı nöronları kapatarak her adımda 2^N alt ağı oluşturur.



4. Sadece sayıda sub-networkten ortak kısmı çıkararak için sadece bir geçişle yapılar 26/09/2026
 !!! Dropout sadece train aşamasında kullanılır / val ve test aşamasında nöron kapatılmaz

? Nöronların %50'sini kapatma: Test aşamasında tüm nöronlar kullanıldığı için sayı iyi tutar ancak güçsüz → inverted Dropout

inverted Dropout:

- Okutulan eğitimi ağırlarında yap

- eğitimi ağırlarında (1-p) ile böl

ISPA? Beklenen değeri korur

Activeşyon fonksiyonu → A

Kapama oranı → p

Real tutulan oranı → 1-p

$M = \begin{cases} 1 & \text{olasılık} \rightarrow 1-p \\ 0 & \text{olasılık} \rightarrow p \end{cases}$

Maskeleme = $1 * (1-p) + 0 * p = 1-p$

Eğitimi

Singül geçiş testleri: singül geçişe eşit güç

DROPOUT				
Epoch	N1	N2	N3	N4
	✓	x	✓	✓
Epoch-2	N1	N2	N3	N4
	✓	✓	x	✓
Epoch-3	N1	N2	N3	N4
	✓	x	✓	x

↑ dropout → underfitting
 ↓ dropout → overfitting

$$A_{dropout} = \frac{A \cdot M}{1-p}$$

$$\frac{A \cdot 1-p}{1-p} = A$$

→ Aktivasyon fonksiyonu ve maskeyi 50

ÖRNEK $A = [2.0, 4.0, 6.0, 8.0]$

Toplam bilgi (singel) $\rightarrow 20$

27/09/2026

$Next = [1, 0, 1, 0]$

girisin kapatilic

gizli bilgi

bilgi $\rightarrow 2*1 + 4*0 + 6*1 + 8*0 \rightarrow 8.0$ kayboldu

$Almask = 2$, $A_{mask} \Rightarrow 16$, bilgi daha fazla 1-0.5 karundu

inverted Dropout'un normal Dropout'tan farklı çok fazla nöronun kapatilmasiyla karsin kulan 42 sayida nöronun bilgisini (öğrenimi) gıcıklatirir.

Backprop.

! Giris katmanina dropout uygulanir Middle Layer

Forward $\rightarrow A_{drop} = \frac{A.M}{1-p}$

Backward $\rightarrow \frac{\partial loss}{\partial A} = \frac{\partial loss}{\partial A_{drop}} \cdot \frac{\partial A_{drop}}{\partial A}$

$\frac{\partial A_{drop}}{\partial A} \rightarrow A.M_{mask}$
olmufunda $\Rightarrow \frac{M}{1-p}$

direk waste dir

Sonuç


$\frac{\partial loss}{\partial A} = \frac{\partial loss}{\partial A_{drop}} \cdot \frac{M}{1-p}$

maskesi 0 olan (silen) nöronların gradyanı 0 olur, güncellenir.

maskesi 1 olan (gözetilen) nöronların gradyanı da 1-p biçiminde güncellenir.

! Nöronlar geçici olarak kapatılır. Her epoch farklı nöron kombinasyonları yapılır

* Model yeni yollar öğrenmeye başlar




41 Early Stopping

27/09/2026

epoch $\rightarrow$ underfitting
epoch $\rightarrow$ overfitting

- val loss $\uparrow$ ise, her şey yolunda modelin tahmini iyi
- val loss $\downarrow$ ise, model train verilerini ezberliyor
- model daha fazla bosa ezber yapmadan eğitimi otomatik olarak durdurur



! A ve B gibi hafif düşüşler loss'te $\emptyset$ kusur verdir bu kusurlara daha dikkatli olmak için patient parametresi kullanılır

En iyi loss skorunu gördükten sonra N epoch bekle $\rightarrow$ daha iyi (data desteği loss) skor gelmezse eğitimi durdur.

Restore-best-weights $\rightarrow$ patient algılayıcılığı epoch'un ayarlanmasında bir kopyasını (yedekini) alır.

! 150 $\rightarrow$ 170 loss $\uparrow$ 0 zaman birer patient için epoch sayısına bakıldığında 150. epoch girilince loss kullandırılır.

min-delta $\rightarrow$ Yeni bir rekor sayılabilecek için loss düşerindeci ve eksiye düşer miktarı

ÖRNEK $\delta = 0.01$


$\delta = 0.0001$
Loss 1 Loss 2 Loss 1 Loss 2
100,982 100,980 100,982 100,980

Eğitim devam eder

Chapter-2 Final Project

28 / 08 / 2024

Motor - performance - predictor



hedef:

RPM (motor devri) →

800 - 4500

RPM

RPM → Revolutions Per Minute

devir / dk

→ veriye ilişkin veriler dataset üzerinde eğitimi yapar

PROJE = UCI / Gerçek Elektrik Motoru Veri Seti

(PMSM) → Permanent Magnet Synchronous Motor

— Motor Yapısı → dönen kısımda elektrik sarjları yerine güç ve kalıcı manyetizeler bulunur.

Sensörler: Akım bileşenleri (i_d , i_q), Voltaj bileşenleri (U_d , U_q), Sargı sıcaklığı, Stator sıcaklığı,

Hedef: Motor devri (motor speed) & Torque

* Enerji verimliliği (EV) ve otomatik kontrol sistemi